UNIWERSYTET EKONOMICZNY W POZNANIU

Jan A

Liczba restauracji i punktów gastronomicznych w Polsce w latach 2008-2023

Projekt ekonometryczny

Kierunek: Informatyka i Ekonometria

Poznań 2025

1. Uzasadnienie wyboru tematu (zmiennej objaśnianej Y)

Wybraliśmy ten temat, ponieważ liczba restauracji i punktów gastronomicznych w latach 2008-2023 jest interesujący. Pozwala zrozumieć, jak różne czynniki społeczne i gospodarcze wpływały na rozwój tej branży. Restauracje odgrywają ważną rolę w codziennym życiu ludzi, a ich liczba może być dobrym wskaźnikiem zmian w poziomie życia, nawykach konsumenckich czy ogólnej sytuacji gospodarczej. Wybór tego tematu pozwala także przeanalizować, jak wielkie wydarzenia, takie jak kryzys finansowy, ogólny rozwój technologii, czy pandemia COVID-19, wpłynęły na sektor gastronomiczny. To badanie może dostarczyć cennych wniosków zarówno dla przedsiębiorców, jak i dla instytucji publicznych.

2. Opis zmiennych objaśniających X

Średnie dochody miesięczne – Dochody mają bezpośredni wpływ na wydatki na jedzenie poza domem. Wyższe dochody sprzyjają częstszemu korzystaniu z restauracji i rozwijaniu się sektora gastronomicznego.

Stopa bezrobocia – Wysokie bezrobocie ogranicza zdolność ludzi do wydawania pieniędzy na dobra i usługi luksusowe, w tym jedzenie poza domem. Z kolei spadek bezrobocia zwykle zwiększa liczbę potencjalnych klientów restauracji.

Wskaźnik inflacji (CPI) – Wzrost cen może zmniejszyć popyt na usługi gastronomiczne, ponieważ jedzenie poza domem staje się droższe w porównaniu do posiłków przygotowywanych w domu.

Gęstość zaludnienia – Gęstość zaludnienia odzwierciedla potencjalną liczbę klientów w danym regionie. Obszary o wysokiej gęstości ludności są atrakcyjniejsze dla inwestorów otwierających restauracje.

Stosunek młodych ludzi do ogólnej liczby ludności - Młodzi ludzie częściej korzystają z restauracji i kawiarni, dlatego większy udział tej grupy w populacji może stymulować rozwój sektora gastronomicznego.

Stopień wykorzystania bazy noclegowej – Im wyższy stopień wykorzystania bazy noclegowej tym większa liczba restauracji. Obszar jest atrakcyjny dla restauratorów, ponieważ jest duża liczba ludności

3. Postać modelu hipotetycznego

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \varepsilon$$

Y: Liczba restauracji i punktów gastronomicznych (zmienna objaśniana),

β_0: Wyraz wolny (wartość liczby restauracji, gdy wszystkie zmienne objaśniające są równe 0),

X_1: Średnie dochody miesięczne na osobę (zł),

X_2: Stopa bezrobocia (%),

X_3: Wskaźnik inflacji (CPI),

X_4: Gęstość zaludnienia(liczba ludności/km^2),

X_5: Stosunek młodych ludzi do ogólnej liczby ludności(%),

X_6: Stopień wykorzystania miejsc noclegowych(%),

$\beta_1, \beta_2, \ldots, \beta_6$: Parametry modelu, które pokazują wpływ poszczególnych zmiennych objaśniających na Y,

ε: Składnik losowy (błąd), który uwzględnia wpływ innych czynników niemodelowanych.

4. Dane pierwotne

Lata	Restauracje i punkty gastronomiczne Y	Średnie dochody miesięczne na osobę (zł) X1	Stopa bezrobocia (%) X2	Wskaźnik inflacji (CPI) X3	Gęstość zaludnienia (liczba ludności/km^2) X4	Stosunek młodych ludzi do ogólnej liczby ludności (%) X5	Stopień wykorzystania bazy noclegowej (%) X6
2008	13069,00	3158,48	9,50	104,20	122,00	23,42	37,59
2009	13305,00	3315,38	12,10	103,50	122,10	22,96	35,75
2010	14408,00	3435,00	12,40	102,60	123,20	22,17	34,27
2011	13886,00	3625,21	12,50	104,30	123,30	21,61	34,5
2012	15137,00	3744,38	13,40	103,70	123,20	20,95	33,6
2013	15807,00	3877,43	13,40	100,90	123,10	20,20	33,8
2014	17325,00	4003,99	11,40	100,00	123,10	19,47	34,8
2015	18611,00	4150,86	9,70	99,10	122,90	18,79	36,7
2016	19623,00	4290,52	8,20	99,40	122,90	18,17	38,1
2017	19125,00	4527,89	6,60	102,00	122,90	17,58	39,3
2018	17700,00	4834,76	5,80	101,60	122,80	17,02	40,1
2019	20260,00	5181,63	5,20	102,30	122,70	16,53	40,6
2020	17778,00	5523,32	6,30	103,40	121,80	15,99	26,8
2021	18789,00	6001,02	5,80	105,10	121,20	15,66	32,3
2022	20215,00	6705,62	5,20	114,40	120,80	15,44	40,4
2023	22187,00	7595,30	5,10	111,40	119,90	15,35	40,5

Źródła danych:

Główny Urząd Statystyczny (GUS)

https://bdl.stat.gov.pl/bdl/dane/podgrup/temat

5. Regresja Krokowa

Po wykonaniu regresji krokowej wstecz, usunęliśmy zmienne nieistotne. W wyniku czego zostały nam następujące zmienne:

X_1: Średnie dochody miesięczne na osobę (zł),

X_3: Wskaźnik inflacji (CPI),

X_6: Stopień wykorzystania miejsc noclegowych(%),

Lata	Restauracje i punkty gastronomiczne Y	Średnie dochody miesięczne na osobę (zł) X1	Wskaźnik inflacji (CPI) X3	Stopień wykorzystania bazy noclegowej (%) X6
2008	13069,00	3158,48	104,20	37,59
2009	13305,00	3315,38	103,50	35,75
2010	14408,00	3435,00	102,60	34,27
2011	13886,00	3625,21	104,30	34,5
2012	15137,00	3744,38	103,70	33,6
2013	15807,00	3877,43	100,90	33,8
2014	17325,00	4003,99	100,00	34,8
2015	18611,00	4150,86	99,10	36,7
2016	19623,00	4290,52	99,40	38,1
2017	19125,00	4527,89	102,00	39,3
2018	17700,00	4834,76	101,60	40,1
2019	20260,00	5181,63	102,30	40,6
2020	17778,00	5523,32	103,40	26,8
2021	18789,00	6001,02	105,10	32,3
2022	20215,00	6705,62	114,40	40,4
2023	22187,00	7595,30	111,40	40,5

6. Postać modelu teoretycznego

$$\hat{Y} = 39373,26 + 2,54X_1 - 399,73X_3 + 210,36X_6$$

Jeżeli średnie dochody miesięczne wzrosną o 1zł to liczba restauracji wzrośnie średnio o 3.

Jeżeli wskaźnik inflacji (CPI) wzrośnie o 1 jednostkę to liczba restauracji zmaleje średnio o 400.

Jeżeli stopień wykorzystania bazy noclegowej wzrośnie o 1% to liczba restauracji wzrośnie średnio o 210.

Wyrazu wolnego nie interpretujemy, ponieważ w danym modelu nie ma on sensu praktycznego.

7. Testy sprawdzające założenia KRL (Klasycznej Regresji Liniowej)

Przeprowadziliśmy łącznie 4 testy, które sprawdzały:

- Liniowość (RESET)

- Homoskedastyczność (White)

- Autokorelację (Durbin-Watson)

- Rozkład normalny składników losowych (JBT)

naszego modelu.

RESET

Hipoteza zerowa: model ma postać liniową.

Hipoteza alternatywna: model ma postać inną niż liniową.

F empiryczne	2,88
F krytyczne	4,10
F istotność	0,10

$F_{empiryczne} < F_{krytyczne}$

$F_{istotność} > 0,05$ (poziom istotności α)

Decyzja: Brak podstaw do odrzucenia Hipotezy zerowej – model ma postać liniową.

White

Hipoteza zerowa: składnik losowy jest homoskedastyczny.

Hipoteza alternatywna: składnik losowy jest heteroskedastyczny.

F empiryczne	0,50
F krytyczne	4,10
F istotność	0,83

$F_{empiryczne} < F_{krytyczne}$

$F_{istotność} > 0,05$ (poziom istotności α)

Decyzja: Brak podstaw do odrzucenia Hipotezy zerowej – składnik losowy jest homoskedastyczny.

Durbin-Watson

Hipoteza zerowa: brak autokorelacji składnika losowego.

Hipoteza alternatywna: autokorelacja składnika losowego.

DW=	2,19	**d'=4-d**	1,81
dL	0,86	d'>dU	
dU	1,73		

Decyzja: Brak podstaw do odrzucenia Hipotezy zerowej – brak autokorelacji składnika losowego.

JBT

Hipoteza zerowa: składnik losowy ma rozkład normalny.

Hipoteza alternatywna: składnik losowy ma rozkład inny niż normalny.

JBT	0,91874451	JBT<Chikwadrat
Chikwadrat	5,99146455	

Decyzja: Brak podstaw do odrzucenia hipotezy zerowej. Składnik losowy ma rozkład normalny.

8. Badanie dobroci modelu

Chcąc zbadać, czy nasz model jest dobrze dopasowany wyliczyliśmy:

Współczynnik determinacji R^2

R^2 = 92,73%

Oznacza to, że model wyjaśnia 92,73% naszej zmiennej objaśnianej Y.
Nasze R^2 > 90% więc model jest dobrze dopasowany.

Współczynnik indeterminacji Φ^2

Φ^2 = 7,27%

Oznacza to, że model nie wyjaśnia 7,27% naszej zmiennej objaśnianej Y.

Odchylenie standardowe składnika losowego s

s= 834,41

Oznacza to, że faktyczna liczba restauracji i punktów gastronomicznych różni się od liczby w modelu średnio o 834.

Współczynnik zmienności losowej V

V= 4,82%

Oznacza to, że składnik losowy wpływa na naszą zmienną objaśnianą Y w 4,82%.
V<10% więc jest akceptowalny

Błąd szacunku parametrów d

d_0 (wyraz wolny) = 6984,28

Szacując wyraz wolny mylimy się przeciętnie o plus/minus 6984,28 względem jego nieznanej, rzeczywistej wartości.

d_1 (Średnie miesięczne dochody na osobę) = 0,23

Szacując parametr b_1 mylimy się przeciętnie o plus/minus 0,23 względem jego nieznanej, rzeczywistej wartości.

d_3 (Wskaźnik inflacji (CPI)) = 74,01

Szacując parametr b_3 mylimy się przeciętnie o plus/minus 74,01 względem jego nieznanej, rzeczywistej wartości.

d_6 (Poziom wykorzystania bazy noclegowej) = 59,70

Szacując parametr b_6 mylimy się przeciętnie o plus/minus 59,70 względem jego nieznanej, rzeczywistej wartości.

Weryfikacja istotności zmiennych objaśniających

Wyraz wolny:

p-wartość = 0,00 < 0,05 (poziom istotności α)
$|t| = 5,64 > t\alpha = 2,18$
przedział ufności (24155,83; 54590,69) – przedział nie zawiera 0

Zmienna istotna

b_1 (Średnie miesięczne dochody na osobę):

p-wartość = 0,00 < 0,05 (poziom istotności α)
$|t| = 10,87 > t\alpha = 2,18$
przedział ufności (2,03; 3,05) – przedział nie zawiera 0

Zmienna istotna

b_3 (Wskaźnik inflacji (CPI)):

p-wartość = 0,00 < 0,05 (poziom istotności α)
$|t|$ = 5,40 > $t\alpha$ = 2,18
przedział ufności (-560,99; -238,48) – przedział nie zawiera 0

Zmienna istotna

b_6 (Poziom wykorzystania bazy noclegowej):

p-wartość = 0,00 < 0,05 (poziom istotności α)
$|t|$ = 3,52 > $t\alpha$ = 2,18
przedział ufności (80,29; 340,44) – przedział nie zawiera 0

Zmienna istotna

Test istotności wektora parametrów (bez wyrazu wolnego)

F= 51,04 < Fα= 3,49
F istotność = 0,00 < 0,05 (poziom istotności α)

Wektor parametrów (bez wyrazu wolnego) istotny

Wniosek:

Model oceniamy jako dobry, ponieważ:
- Współczynnik determinacji R^2 > 90% (92,73%)
- Współczynnik zmienności losowej V < 10% (4,82%)
- Wszystkie zmienne wprowadzone do modelu są istotne. Wszystkie parametry znajdują się w granicach przedziałów ufności. Wektor parametrów jest istotny.

9. Modele jednowymiarowe

Dla każdej zmiennej objaśniającej oszacowaliśmy 5 modeli (liniowy, parabolę, hiperbolę, wykładniczy i potęgowy), aby później móc wyliczyć wartości tych zmiennych dla roku następnego tj. 2024.

X1 – Średnie dochody miesięczne na osobę (zł)

Najlepiej dopasowanym modelem okazał się model wykładniczy, ponieważ:

- R^2 = 95,5% (najwyższe ze wszystkich innych modeli)
- V = 0,67% (<10%)
- Wszystkie zmienne istotne

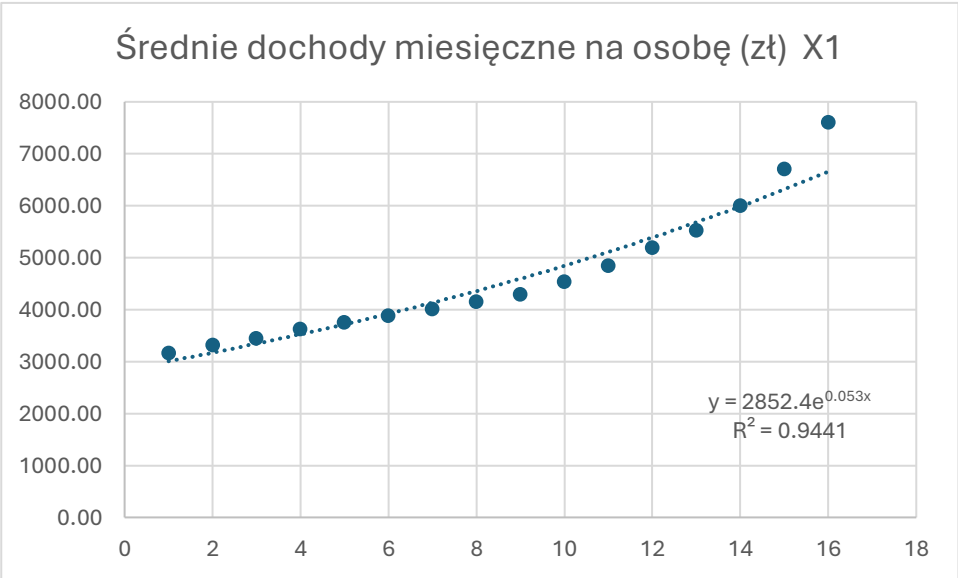

Pomocniczy model liniowy:

$$\widehat{W} = 7{,}96 + 0{,}05X$$

Model oryginalny:

$$X_1 = 2852{,}43e^{0{,}05t}$$

Interpretacja:

Co roku w latach 2008-2023 średnie miesięczne dochody na osobę wzrastały przeciętnie o 5%. W roku 2007 teoretyczne średnie miesięczne dochody na osobę wynosiły 2852,43 zł.

X3 – Wskaźnik inflacji (CPI)

Najlepiej dopasowanym modelem okazała się parabola, ponieważ:

-R^2 = 76,82 (najwyższe ze wszystkich innych modeli)
-V = 2,03 (<10%)
-Wszystkie zmienne istotne

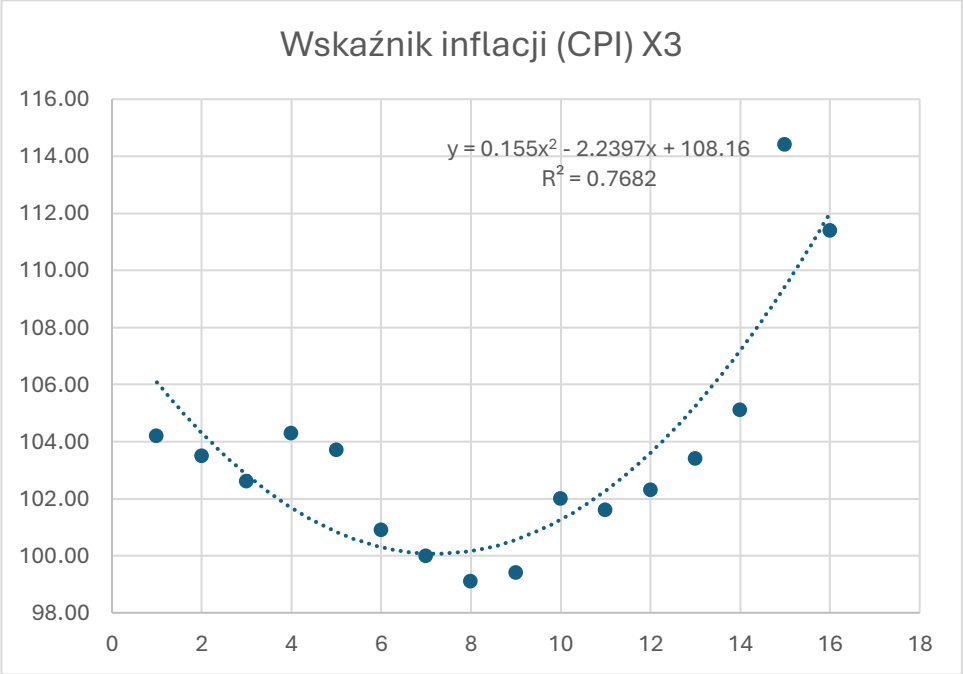

Pomocniczy model liniowy:

$$\hat{Y} = 108{,}16 - 2{,}24X + 0{,}16Z$$

Model oryginalny:

$$X_3 = 108{,}16 - 2{,}24t + 0{,}16t^2$$

Współrzędne wierzchołka:
X_w=7,22 Y_w= 100,07

Interpretacja:
Najmniejsza wartość wskaźnika inflacji (CPI) równa 100,07 występuje w roku 2014 (w naszej numeracji 7,22)

X6 – Stopień wykorzystania bazy noclegowej (%)

W związku z tym, że w latach 2020-2021 wybuchła pandemia COVID-19 stopień wykorzystania bazy noclegowej drastycznie spadł w stosunku do poprzednich lat. Próbując oszacować modele na oryginalnych danych wychodziły nam we wszystkich modelach zmienne nieistotne, R^2 na poziomie 3%, a V na poziomie 11%. Nie były to wyniki akceptowalne. W 2022 sytuacja się ustabilizowała do wartości sprzed pandemii. Z tego powodu pozwoliliśmy sobie przekształcić dane z lat 2020-2021 na średnią arytmetyczną z lat 2019 i 2022, ponieważ była to sytuacja, której nikt nie przewidział i nie można było tego przewidzieć.

Działając na przekształconych danych najlepiej dopasowanym modelem okazał się model wykładniczy, ponieważ:

-R^2 = 65,21 (nie jest to najwyższy wynik, ale za to w tym przypadku wszystkie zmienne są istotne)
-V = 1,25 (<10%)
-Wszystkie zmienne istotne

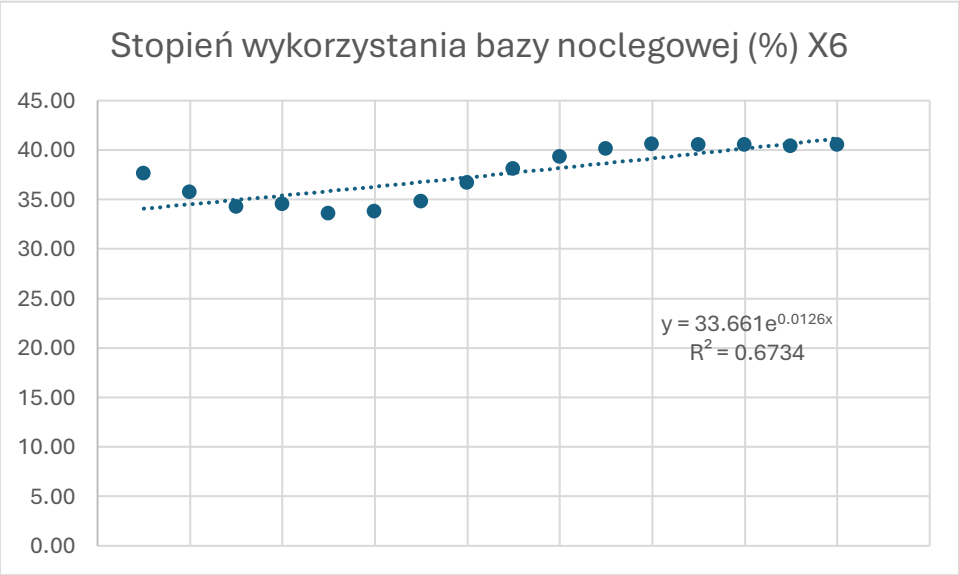

Pomocniczy model liniowy:

$$\widehat{W} = 3{,}52 + 0{,}01X$$

Model oryginalny:

$$X_6 = 33{,}66e^{0{,}01t}$$

Interpretacja:
Co roku w latach 2008-2023 stopień wykorzystania bazy noclegowej wzrastał przeciętnie o 1%. W roku 2007 teoretyczny stopień wykorzystania bazy noclegowej wynosił 33,66%.

10. Prognoza punktowa Y na 2024 rok

Dla oszacowanych modeli nieliniowych dla zmiennych objaśniających X wyliczyliśmy ich wartości dla roku 2024 (t+1=17)

$$X_1 = 2852{,}43e^{0{,}05t}$$

X_1^{t+1}=6673,68

W roku 2024 średnie miesięczne dochody na osobę są prognozowane na poziomie 6673,68zł.

$$X_3 = 108{,}16 - 2{,}24t + 0{,}16t^2$$

X_3^{t+1}=116,32

W roku 2024 wskaźnik inflacji (CPI) jest prognozowany na poziom 116,32.

$$X_6 = 33{,}66e^{0{,}01t}$$

X_6^{t+1}=39,90

W roku 2024 stopień wykorzystania bazy noclegowej jest prognozowany na poziom 33,90%

Po podstawieniu tych wartości do modelu teoretycznego:

$$\hat{Y} = 39373{,}26 + 2{,}54X_1 - 399{,}73X_3 + 210{,}36X_6$$

otrzymujemy $\hat{Y}_{t+1}$ = 18 200.

Oznacza to, że w roku 2024 liczba restauracji i punktów gastronomicznych jest prognozowana na poziomie 18 200.

11. Weryfikacja merytoryczna

Cały nasz model oceniamy pozytywnie. Współczynnik determinacji wyszedł nam wysoki, współczynnik zmienności losowej odpowiednio niski i wszystkie zmienne istotne. Model przeszedł pozytywnie wszystkie testy na liniowość, homoskedastyczność, autokorelację i rozkład normalny składnika losowego. Po regresji krokowej usunęliśmy zmienne z modelu, które w niewystarczający sposób opisywały naszą zmienną objaśnianą., zostawiając same zmienne istotne.

Jedyną rzeczą jaką byśmy zrobili inaczej to wzięcie większego zakresu lat (więcej niż 16). Mogłoby się wtedy okazać, że dwie wartości odstające spowodowane pandemią, nie zaburzyłyby dopasowania modeli jednowymiarowych.